Ensamble frente al modelo destilado

Mamíferos de Colombia · Jaime Andrés Ortega Cadena · David Alejandro Muñoz Carmona

1. Tabla comparativa de escenarios (2.458 fotos de prueba de Colombia, nunca vistas)

Escenario	Accuracy validación	Accuracy prueba	F1 macro prueba	Top-3 prueba	Tamaño (MB)	Latencia CPU (ms/foto)	¿Cabe en el celular?
Modelo individual v2 (EfficientNetV2-S)	—	92,76 %	—	—	262,0	—	No
Modelo individual v4 (EfficientNetV2-S)	92,57 %	93,12 %	0,913	98,21 %	369,0	—	No
Ensamble por promedio (0,5 / 0,5)	92,66 %	—	—	—	630,5	2.357,8	No
Ensamble ponderado (0,4 / 0,6 + TTA)	92,78 %	93,73 %	0,920	98,49 %	630,5	4.715,6	No
Modelo híbrido: ensamble ponderado + ubicación	95,30 %	95,36 %	0,941	98,82 %	630,5	4.715,6	No
Modelo destilado MobileNetV3 (Keras)	89,36 %	90,76 %	0,876	97,68 %	12,8	246,3	No
Destilado + ubicación (Keras)	92,20 %	93,53 %	0,919	97,84 %	12,8	246,3	No
Destilado + ubicación en TFLite float16 (la app)	**—**	**93,69 %**	**—**	**—**	**6,1**	**3,7**	**Sí**

En verde, el escenario que queda en la app. Latencia medida en CPU, una foto a la vez (como en un celular). Ensamble = 2 EfficientNetV2-S (260 px). Destilado = MobileNetV3-Large (224 px) en TFLite float16. Ubicación = ajuste por departamento con α y λ elegidos con validación. Con TTA cada modelo grande se ejecuta dos veces (2 × 2.357,8 ms medidos). — = no se midió en esa corrida; el cuaderno de esta semana completa todas las casillas.

2. Conclusión: qué modelo se queda en la app y por qué

Combinar modelos sí mejora el acierto. El ensamble ponderado (pesos 0,4 / 0,6 elegidos con validación, más la foto volteada) llega a 93,73 % en prueba y 0,920 de F1 macro, frente a 93,12 % del mejor modelo individual. El promedio simple queda casi igual en validación (92,66 % vs. 92,78 %): ponderar ayuda poco porque los dos modelos tienen la misma arquitectura y aciertan parecido. El modelo híbrido, que suma a la imagen la información de dónde se tomó la foto, es el más preciso: 95,36 % de accuracy y 0,941 de F1, y es el único que cumple la meta de 94 %.

Pero el ensamble pesa 630,5 MB y tarda 2,4 segundos por foto en CPU (el doble con TTA). No cabe en un celular de gama media y obligaría a enviar cada foto a un servidor, algo imposible en campo, donde casi nunca hay señal.

Por eso en la app se queda el modelo destilado MobileNetV3-Large en TFLite float16 con el ajuste por ubicación. Pesa 6,1 MB (100 veces menos), clasifica una foto en 3,7 ms (más de 600 veces más rápido que el ensamble) y funciona sin internet. Su acierto en prueba es 93,69 %: solo 1,7 puntos por debajo del híbrido con ensamble, y por encima del ensamble que usa solo la imagen. La ubicación le suma más de 3 puntos casi sin costo, porque es solo una tabla de factores por departamento.

El ensamble no se descarta: es el profesor que le enseñó al modelo destilado, y puede usarse en el panel web para revisar las fotos con confianza baja que lleguen de campo. Además, en la app MegaDetector revisa primero si hay un animal, y cuando la confianza es baja se muestran las tres especies más probables para que la persona confirme.