Informe de auditoría del modelo final

Mamíferos de Colombia: clasificación de 40 especies en fotos de cámaras trampa · Semana 15, Momento 3

Jaime Andrés Ortega Cadena · ID 828281

David Alejandro Muñoz Carmona · ID 821249

Cuaderno: S15_Auditoria_Ortega_Munoz.ipynb

1. Qué se auditó y cómo

Se auditó el modelo que corre en la app: el estudiante **MobileNetV3-Large destilado** (224 px, los mismos pesos que el archivo TFLite float16 de 6,1 MB) más el **ajuste por ubicación** según el departamento ($\alpha = 1$, $\lambda = 1$, elegidos con validación). Antes de clasificar, la app usa **MegaDetector V6** para descartar fotos sin animal.

La auditoría usa las **2.458 fotos de prueba**: solo de Colombia, separadas por registro GBIF y nunca vistas al entrenar. Sobre ellas se midió precision, recall y F1 por clase, la matriz de confusión, las curvas ROC y Precision-Recall, el umbral de confianza, tres semillas, la robustez ante cuatro alteraciones y Grad-CAM. Además, se probaron **60 fotos reales de la región** en la app, en un celular Samsung SM-M156B.

2. Hallazgos principales

93,65 %
accuracy en prueba (F1 macro 0,921)

93,2 ± 0,2 %
accuracy con tres semillas

97,4 %
acierto de las respuestas «seguras» (confianza ≥ 0,61)

2,8 s
respuesta en el celular (mediana; 35 ms es la especie)

- **El modelo es preciso y estable.** Logra 93,65 % de accuracy, 97,97 % en top-3 y un AUC ROC macro de 0,997. Con las tres semillas (remuestreo de la prueba y perturbaciones) la desviación es de solo 0,23 puntos. La ubicación sube el acierto de 90,48 % (solo imagen) a 93,65 %. **35 de las 40 especies** tienen F1 ≥ 0,85.
- **Casi todos los errores son entre especies parecidas.** Los pares que más se confunden son zaino → pecarí labiado (19,6 % de los zainos), ñeque negro → ñeque (21,2 %), ardilla andina → ardilla colirroja (17,6 %), mapache cangrejero → chucha común (14,8 %) y mono ardilla ↔ mono ardilla ecuatoriano.
- **La confianza sirve para detectar errores** (AUC 0,90). Con el umbral de **0,61**, elegido en validación para que las respuestas seguras acierten al menos el 97 %, la app responde con seguridad el 89 % de las fotos y acierta el 97,4 %. Del 11 % restante solo el 62,8 % es correcto, pero la especie real está en el top-3 en el 86,1 %. Ahí conviene decir «no estoy seguro» y mostrar las tres opciones.
- **El modelo mira al animal, no al fondo.** En los 10 aciertos Grad-CAM marca la cara, las manchas o la cola. En los errores con más confianza también mira al animal, pero las especies se diferencian por detalles finos de color que la foto no muestra bien (figura 2).
- **Es frágil ante fotos de mala calidad** (figura 1). El acierto cae 14 puntos con desenfoque, 13 con oclusión, 26 con poca luz y 30 con otro fondo. La prueba de «otro fondo» es exigente: el borde se reemplaza con el de otra foto y a veces incluye partes de otro animal. Aun así, muestra que el contexto influye.

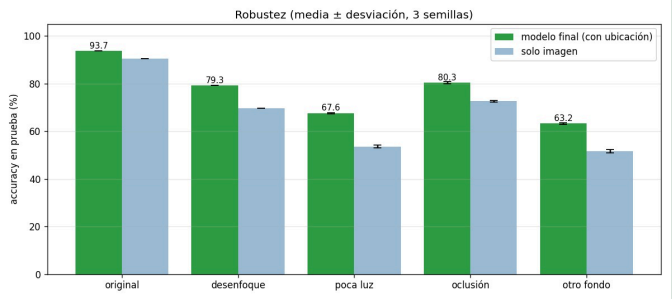


Figura 1. Accuracy en prueba bajo cuatro alteraciones (media ± desviación, 3 semillas). Verde: modelo final con ubicación; azul: solo imagen.

Prueba en la app con 60 fotos de la región

Se eligieron 60 fotos del conjunto de prueba registradas en Cundinamarca, Caldas, Valle, Risaralda, Huila, Quindío, Tolima y otros departamentos (34 especies). Cada una llevaba el GPS de su departamento. Se cargaron en la app con internet.

Resultado	Valor
Fotos analizadas / descartadas por MegaDetector	51 / 9
Accuracy en las 51 analizadas	92,2 %
Top-3 en las 51 analizadas	96,1 %
Confianza media: aciertos / errores	0,86 / 0,25

Respuestas con confianza ≥ 0,61 (acierto)	43 (100 %)
Tiempo total: mediana / p95	2.785 / 7.275 ms
MegaDetector / clasificador (mediana)	2.749 / 35 ms

Los 4 errores (oso de anteojos, zorro perruno, puma y ocelote) tuvieron confianza menor a 0,35. Con el umbral de 0,61 los cuatro se habrían marcado como «no estoy seguro».

3. Las tres clases con peor desempeño y por qué

Especie	Precision	Recall	F1	Fotos de entrenamiento / prueba	Con qué se confunde y por qué
Ñeque negro	0,71	0,76	0,74	362 / 33	Con el **ñeque** (21 % de sus fotos), y al revés. Son especies hermanas con el mismo cuerpo; solo cambia el tono del pelaje, que con poca luz o en blanco y negro casi no se distingue. El ñeque tiene casi el doble de fotos (646), por eso el modelo tiende a elegirlo.
Ardilla andina	0,79	0,76	0,78	156 / 34	Con la **ardilla colirroja** (18 %). Tienen forma y postura iguales y la colirroja es la clase más grande del dataset (1.200 fotos, 7,7 veces más). En el Grad-CAM el modelo mira la cabeza, que es casi igual en las dos; la cola y el color del vientre, que las diferencian, quedan fuera de foco.
Mapache cangrejero	0,84	0,78	0,81	513 / 27	Con la **chucha común** (15 %). Las dos son nocturnas, grises, de hocico largo y aparecen de noche en fotos infrarrojas, donde se pierde el antifaz negro del mapache. Además, en validación y prueba hay pocas fotos de mapache en Colombia (20 y 27).

Un caso que se acerca a estas tres es el **zaino** (F1 0,83), que el modelo confunde con el **pecarí labiado**: son dos pecaríes casi iguales en cámaras trampa nocturnas, y la diferencia (el collar blanco del zaino) suele verse poco (figura 2, derecha).

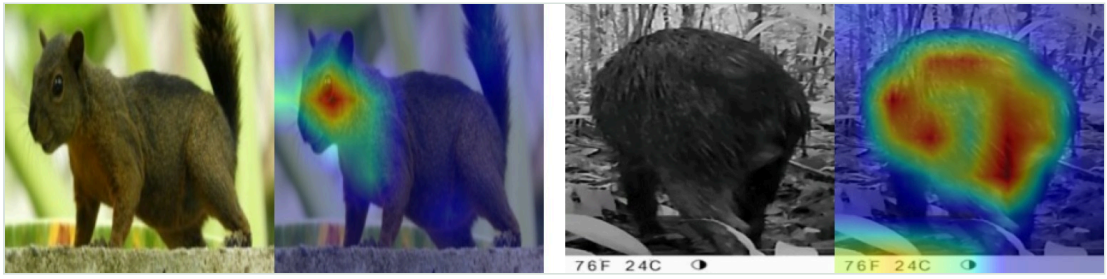


Figura 2. Grad-CAM de dos errores con más del 94 % de confianza. Izquierda: una ardilla andina clasificada como ardilla colirroja; el modelo mira la cabeza, que es igual en ambas. Derecha: un zaino clasificado como pecarí labiado en una cámara trampa nocturna; el modelo mira el cuerpo, pero el collar que las diferencia no se ve.

4. Consecuencias de los errores para quien use la app

La app la usarían técnicos de Cortolima y monitores comunitarios para registrar fauna en el Tolima. Para ellos los errores no pesan igual:

- **Falso positivo:** la app afirma una especie que no es. El riesgo mayor es registrar por error una especie amenazada o de interés, como un oso de anteojos, un jaguar o una danta. Eso produce **registros de presencia falsos**: puede mover recursos de conservación a donde no hacen falta, generar alarmas innecesarias o inflar inventarios. Entre especies hermanas (ñeque / ñeque negro, zaino / pecarí labiado) el error es más silencioso: **mezcla dos poblaciones** en los reportes, y una de ellas (el pecarí labiado) es más sensible a la cacería.

- **Falso negativo:** la app no reconoce una especie que sí está. El caso más claro lo dio la prueba en la app: **MegaDetector descartó 9 de 60 fotos (15 %) que sí tenían un animal**, sobre todo fotos cerradas, de animales entre ramas o nocturnas. Si el usuario confía en el aviso «no se detecta ningún animal», ese registro **se pierde** y la especie se subestima en la zona. Un falso negativo del clasificador (decir otra especie) tiene el mismo efecto para la especie real.
- **Lo que ya los reduce:** la app muestra el top-3 (la especie real está ahí en el 98 % de las fotos de prueba), deja corregir o escribir el nombre, tiene el botón «Sí hay un animal» y sube todo a Firebase para que un biólogo lo valide en el panel web.

5. Límites del modelo

- **Solo conoce 40 especies.** Cualquier otro mamífero (o un ave) recibe el nombre de una de las 40. La confianza baja ayuda a notarlo, pero no lo garantiza.
- **Fotos de mala calidad:** con poca luz el acierto baja a 67,6 % y con desenfoque a 79,3 %. Son condiciones comunes en cámaras trampa al amanecer, al anochecer o con animales en movimiento.
- **MegaDetector no es perfecto con fotos cerradas** (descartó el 15 % en la prueba) y es lento en el celular: 2,7 de los 2,8 segundos de respuesta. El clasificador solo tarda 35 ms.
- **El entrenamiento viene de GBIF**, con muchas fotos de ciencia ciudadana tomadas de cerca y de día. Hay pocas fotos de prueba de algunas especies (oso de anteojos 15, armadillo coletrapo 12) y fuerte desbalance (ardilla andina 156 vs. ardilla colirroja 1.200). El ajuste por ubicación hereda los sesgos de muestreo de GBIF por departamento.
- **La prueba en la app usó fotos del dataset**, que el modelo no vio al entrenar, y no fotos tomadas por nosotros con una cámara trampa en el Tolima. El tiempo de respuesta y el comportamiento de la app son reales, pero el acierto en campo real todavía debe confirmarse con fotos de cámaras de Cortolima.

6. Recomendaciones de uso

- **Subir el umbral de «no estoy seguro» a 0,61.** Hoy la app marca confianza media desde 0,50. Con 0,61 las respuestas seguras aciertan el 97,4 % en prueba y el 100 % en la prueba en la app. Por debajo, el usuario debe elegir entre las tres opciones.
- **No tomar como definitivo un «no se detecta ningún animal».** Si se ve un animal, usar «Sí hay un animal». Conviene bajar el umbral de MegaDetector o probar un detector más liviano que lo haga más rápido.
- **Validar con un biólogo** todo registro de especies amenazadas y de los pares que se confunden (ñeque / ñeque negro, zaino / pecarí, ardillas, mapache / chucha) antes de usarlo en informes oficiales. La app es un apoyo para clasificar, no un reemplazo del experto.
- **Tomar o enviar fotos con buena luz, enfocadas y con el animal completo.** Activar el GPS para que el ajuste por ubicación funcione.
- **Reentrenar con fotos de cámaras trampa de Cortolima** validadas en el panel web, en especial nocturnas y de las especies débiles, y agregar alteraciones de poca luz y desenfoque al entrenamiento.

Evidencia completa (gráficas, tablas y CSV) en el cuaderno S15_Auditoria_Ortega_Munoz.ipynb y en el archivo S15_PruebaCampo_Ortega_Munoz.csv.